

ATIVIDADE I — Machine Learning

Julia Egute e Pedro Perroni
Professor: Antonio Marcos Selmini

1. Introdução

O problema estudado é prever se um cliente irá aderir a um depósito a prazo. Para o banco, essa previsão pode apoiar a priorização de contatos de uma campanha de telemarketing. Como a decisão de ligar ocorre antes da conversa, o modelo principal deve utilizar apenas informações disponíveis nesse momento.

A base fornecida reúne 41.188 contatos de campanhas de um banco português, realizadas entre maio de 2008 e novembro de 2010, conforme o enunciado. São 21 colunas: 20 atributos e a variável-alvo aderiu. Os atributos incluem informações do cliente, histórico de campanhas e indicadores econômicos do período do contato. O objetivo foi preparar os dados, treinar k-NN, Naive Bayes e regressão logística e comparar seus resultados em dois cenários: o principal, voltado à decisão antes da ligação, e o completo, usado para comparação. A classe positiva é a adesão ao produto, representada por sim.

2. Análise exploratória

A base original contém dez atributos numéricos e dez categóricos, além do alvo categórico. Há 36.548 registros de não adesão (88,7%) e 4.640 de adesão (11,3%). Esse desbalanceamento exige avaliar as duas classes: prever sempre não já produziria cerca de 88,7% de acurácia, sem identificar nenhuma adesão.




Figura 1 — Taxa de adesão por profissão na base original.

Estudantes e aposentados apresentam as maiores taxas de adesão. As diferenças descrevem os contatos presentes na amostra e não demonstram que a profissão, isoladamente, determina a contratação. A quantidade de registros por profissão também deve ser considerada na interpretação.

2.1 Relações com a adesão e qualidade da base




Figura 2 — Adesão por mês e relação entre indicadores econômicos, por classe.

A taxa de adesão varia entre os meses. Os indicadores econômicos também se concentram em determinados valores, pois descrevem o período da campanha. Essas relações podem refletir diferenças de contexto e de composição dos contatos; não permitem concluir que mudar o mês ou uma taxa econômica causaria maior adesão.




Figura 3 — Distribuição e média da duração das ligações por classe.

As ligações com adesão duram, em média, aproximadamente 553 segundos, contra 221 segundos nas demais. Apesar dessa associação, a duração não pode apoiar a escolha inicial de quem contatar, pois só será conhecida depois da ligação.

Não foram encontrados valores nulos no arquivo original, mas há informações codificadas como desconhecido. Essa categoria aparece em inadimplente (8.597 registros), escolaridade (1.731), financiamento imobiliário (990), empréstimo pessoal (990), profissão (330) e estado civil (80). A ausência de NaN, portanto, não significa que todos os dados sejam conhecidos.

O valor 999 em dias_desde_ultimo_contato aparece em 39.673 registros (96,3%) e significa ausência de contato anterior, não uma duração real. Também foram identificadas 12 linhas idênticas. As correlações entre indicadores macroeconômicos e a assimetria de variáveis como duração exigem cuidado na interpretação, mas não justificam, por si só, excluir registros.

3. Preparação dos dados

3.1 Limpeza, recodificação e divisão

Foram removidas 12 linhas exatamente duplicadas, sob a hipótese de que eram registros redundantes. A base passou a ter 41.176 registros: 36.537 da classe não e 4.639 da classe sim. Como não há um identificador único do contato, não é possível descartar que algumas linhas iguais representem contatos distintos; essa é uma limitação da decisão adotada.

O alvo aderiu foi separado dos atributos e convertido para 0 (não) e 1 (sim). Criou-se o indicador `nunca_contatado`, igual a 1 quando `dias_desde_ultimo_contato` era 999 e a 0 nos demais casos. O 999 foi substituído por NaN nessa coluna. Assim, o modelo não interpreta esse código como uma quantidade real de dias e mantém a informação de que não houve contato anterior.

A divisão foi realizada uma única vez, com 70% para treino (28.823 registros) e 30% para teste (12.353), usando estratificação pelo alvo e `random_state=42`. O teste contém 10.961 registros da classe não e 1.392 da classe sim. Os mesmos registros de treino e teste foram usados para todos os modelos e nos dois cenários.

3.2 Definição dos cenários

No cenário principal, foram excluídas `duracao_ligacao_seg` e `contatos_campanha_atual`. A duração é desconhecida antes da ligação. A contagem da campanha atual inclui o contato registrado; como a base não fornece explicitamente a contagem disponível antes da decisão, sua exclusão foi uma escolha conservadora. Mantê-las poderia produzir uma avaliação que depende de informações ainda indisponíveis no uso pretendido.

Mês, dia da semana e meio de contato foram mantidos sob a hipótese de que a data e o canal já estão planejados quando o banco prioriza os clientes. Os dados históricos e os indicadores econômicos também foram considerados disponíveis nesse momento. Essas hipóteses precisam ser verificadas em uma aplicação real.

O cenário completo mantém todos os 20 atributos originais, além de `nunca_contatado`. O cenário principal utiliza 19 atributos, após as duas exclusões e a criação do indicador. Esses totais são anteriores à codificação das categorias. O alvo nunca participa da preparação dos atributos.

3.3 Preparação com Pipeline

Nos atributos numéricos, `SimpleImputer` substitui os valores ausentes pela mediana e `StandardScaler` realiza a padronização. Nas categorias, `OneHotEncoder` cria indicadores binários, remove a primeira categoria de cada atributo como referência (`drop="first"`) e permite categorias não vistas no treino (`handle_unknown="ignore"`). A categoria desconhecido foi preservada como informação própria.

As transformações foram reunidas em um `ColumnTransformer` dentro do Pipeline de cada classificador. Medianas, escalas e categorias são aprendidas apenas nos dados usados para treinar cada ajuste, inclusive dentro das partições da validação cruzada. Os modelos usam o mesmo procedimento de preparação. Não houve remoção de valores extremos, balanceamento artificial das classes ou alteração do limiar de classificação.

4. Modelagem

Foram treinados os três classificadores solicitados no enunciado, com a mesma divisão dos dados e o mesmo procedimento de preparação. Os hiperparâmetros foram selecionados por `GridSearchCV`, usando cinco partições estratificadas e F1 macro como critério. A busca foi realizada no conjunto de treino completo, separadamente em cada cenário.

Modelo	Configuração avaliada	Principal	Completo
k-NN	$k \in \{1, 3, 5, 9, 15, 21, 31, 51\}$; pesos uniformes e distância euclidiana.	$k = 5$	$k = 9$

Modelo	Configuração avaliada	Principal	Completo
GaussianNB	Configuração padrão; sem busca de hiperparâmetros.	Padrão	Padrão
Regressão logística	$C \in \{0,001; 0,01; 0,1; 0,5; 1; 5; 10\}$; max_iter = 1.000; random_state = 42.	C = 10	C = 5

4.1 Justificativa dos modelos

O k-NN classifica a partir dos exemplos mais próximos. A padronização é importante porque atributos com escalas maiores poderiam dominar o cálculo das distâncias. O número de vizinhos foi escolhido pelo desempenho médio na validação cruzada, e não por ajustes sobre o teste.

Foi escolhido GaussianNB porque a base contém variáveis numéricas contínuas, cujas magnitudes foram preservadas. Essa escolha permite usar a mesma preparação dos demais classificadores, mas tem limitações: os indicadores binários produzidos pelo OneHotEncoder não seguem uma distribuição gaussiana, e as correlações entre atributos enfraquecem a hipótese de independência do Naive Bayes. Por isso, o modelo foi tratado como uma aproximação e avaliado empiricamente.

A regressão logística foi treinada com regularização, controlada por C. Valores menores de C representam regularização mais forte. O limite de 1.000 iterações foi adotado no notebook. Além das métricas, foram analisados os cinco coeficientes de maior valor absoluto, preservando seus sinais.

4.2 Separação entre ajuste e avaliação

Ao receber cv=5 para classificação, o scikit-learn utiliza partições estratificadas, sem embaralhamento nesse caso. Em cada partição, o Pipeline aprende a preparação somente na parte de treino. Após a busca, a melhor configuração é ajustada novamente sobre todo o conjunto de treino.

No cenário principal, a média e o desvio-padrão do F1 macro foram calculados por validação cruzada para os três modelos finais. O GaussianNB apresentou a maior média e foi escolhido por esse critério. O teste reservado foi usado para medir e comparar o desempenho final, sem participar da busca de hiperparâmetros.

Como k e C foram escolhidos utilizando esse mesmo conjunto de treino, a validação cruzada dos modelos finais pode apresentar algum otimismo. A avaliação no teste separado é, portanto, importante. As médias próximas também não permitem afirmar que um modelo seja estatisticamente superior aos demais.

5. Resultados:

5.1 Métrica principal e comparação

A métrica principal foi o F1 macro, que calcula a média do F1 das duas classes, atribuindo o mesmo peso a cada uma. Isso reduz a influência da classe majoritária na comparação. Acurácia, precisão e recall também foram analisados: a precisão da classe sim indica a proporção de adesões entre as previsões positivas, enquanto seu recall indica a proporção de adesões identificadas.

O F1 macro combina precisão e recall, mas não representa diretamente o custo financeiro dos erros nem dá peso adicional aos falsos negativos. Por isso, a escolha estatística foi acompanhada da análise de erros e das limitações para o negócio.

Cenário modelo /	Classe	Acurácia	Precisão	Recall	F1	F1 macro	CV: média ± DP
Principal k-NN	não	0,8921	0,9137	0,9700	0,9410	0,6545	0,6557 ± 0,0076
	sim		0,5411	0,2787	0,3679		
Principal GaussianNB	não	0,8425	0,9345	0,8845	0,9088	0,6657	0,6585 ± 0,0059
	sim		0,3600	0,5115	0,4226		
Principal Reg. logística	não	0,8989	0,9080	0,9860	0,9454	0,6338	0,6465 ± 0,0113
	sim		0,6585	0,2134	0,3223		
Completo k-NN	não	0,9027	0,9269	0,9666	0,9463	0,7134	—
	sim		0,6030	0,3994	0,4806		
Completo GaussianNB	não	0,8507	0,9433	0,8850	0,9132	0,6903	—
	sim		0,3908	0,5812	0,4674		
Completo Reg. logística	não	0,9089	0,9294	0,9712	0,9498	0,7294	—
	sim		0,6485	0,4188	0,5089		

Tabela 1 — Resultados no teste e validação cruzada no treino. Acurácia e F1 macro referem-se ao modelo, não a uma classe. As células vazias repetem o valor da linha anterior; “—” indica que a média e o desvio-padrão dos modelos finais foram reportados apenas no cenário principal. Fonte: saídas da última versão do notebook.

No cenário principal, o GaussianNB obteve o maior F1 macro médio na validação cruzada ($0,6585 \pm 0,0059$), seguido de k-NN ($0,6557 \pm 0,0076$) e regressão logística ($0,6465 \pm 0,0113$). A pequena diferença para o k-NN recomenda cautela. No teste, o GaussianNB também teve o maior F1 macro desse cenário (0,6657).

No cenário completo, os três modelos elevaram o F1 macro no teste. A regressão logística apresentou o maior valor (0,7294), mas esse resultado inclui informações incompatíveis com a decisão antes da ligação. Assim, ele não justifica substituir o cenário principal pelo completo.

5.2 Matrizes de confusão e custos dos erros

As matrizes utilizam a classe sim como positiva. As linhas representam as classes reais e as colunas, as previstas. Portanto, o canto superior direito contém os falsos positivos (FP), e o inferior esquerdo, os falsos negativos (FN).




Figura 4 — Matrizes de confusão dos seis ajustes no mesmo conjunto de teste.

Um falso positivo ocorre quando o modelo prevê adesão, mas o cliente não adere. Ao usar essa previsão para priorizar contatos, o banco pode gastar tempo de operador e capacidade de atendimento em uma ligação improdutiva. Um falso negativo ocorre quando o modelo prevê não adesão, embora o cliente tenha aderido no registro observado; na priorização, isso pode representar uma oportunidade perdida.

No cenário principal, o GaussianNB identifica 712 das 1.392 adesões (recall de 51,1%), com 1.266 falsos positivos e 680 falsos negativos. O k-NN identifica 388 adesões, com 329 falsos positivos e 1.004 falsos negativos. A regressão logística identifica 297, com 154 falsos positivos e 1.095 falsos negativos.

O GaussianNB recupera mais adesões, mas apenas 36,0% de suas previsões positivas correspondem a adesões. A regressão logística apresenta precisão de 65,9% para sim, porém deixa de identificar a maior parte dos aderentes. Isso mostra que maior precisão não significa maior cobertura das oportunidades.

Consideramos que um falso negativo pode custar mais por ocorrência, caso a oportunidade de captação perdida supere o custo de uma ligação. Essa é uma hipótese de negócio, não um valor medido na base. Muitos falsos positivos também podem gerar um custo total alto. Sem custos de contato, retorno esperado e capacidade da equipe, não é possível afirmar qual modelo maximiza o resultado financeiro do banco.

5.3 Cinco coeficientes de maior magnitude

Na regressão logística, foram selecionados os cinco coeficientes de maior valor absoluto em cada cenário. Um sinal positivo indica associação com maior probabilidade prevista de adesão; um sinal negativo indica o contrário, mantendo os demais atributos constantes.

Nas variáveis numéricas padronizadas, a interpretação considera um aumento de um desvio-padrão calculado no treino. Nas variáveis categóricas, compara-se a categoria indicada com a referência removida na codificação. Os coeficientes representam mudanças no logaritmo das chances, e não variações diretas em pontos percentuais.

Atributo principal — cenário	Coeficiente	Interpretação
Taxa de variação do emprego	-2,3182	Valores maiores se associam a menor probabilidade prevista de adesão.
Mês: março	+1,3941	Março se associa a maior probabilidade prevista que abril, a referência.
Índice de preços ao consumidor	+1,1175	Valores maiores se associam a maior probabilidade prevista de adesão.
Meio de contato: telefone fixo	-0,7983	Telefone fixo se associa a menor probabilidade prevista que celular.
Campanha anterior: sucesso	+0,7942	Sucesso anterior se associa a maior probabilidade prevista que fracasso.

Tabela 2 — Cinco maiores coeficientes em valor absoluto no cenário principal. Fonte: notebook da atividade.

A taxa de variação do emprego apresenta o maior valor absoluto nesse ajuste. Entretanto, variáveis numéricas padronizadas e indicadores de categorias têm unidades diferentes; essa ordenação não deve ser tratada como uma medida universal de importância. As relações também podem mudar quando atributos correlacionados são incluídos ou retirados.

Atributo completo — cenário	Coeficiente	Associação prevista
Taxa de variação do emprego	-2,5820	Menor adesão com o aumento do indicador.
Mês: março	+1,8223	Maior adesão em relação a abril.
Duração da ligação	+1,2398	Maior adesão com o aumento da duração.
Euribor de 3 meses	+1,1640	Maior adesão com o aumento da taxa.
Índice de preços ao consumidor	+0,9972	Maior adesão com o aumento do índice.

Tabela 3 — Cinco maiores coeficientes em valor absoluto no cenário completo. Fonte: notebook da atividade.

A presença da duração entre os maiores coeficientes no cenário completo reforça sua associação com a adesão. Isso não torna o atributo disponível antes da ligação nem demonstra que prolongar uma conversa causaria a contratação. Da mesma forma, os indicadores econômicos representam o contexto histórico das campanhas, e suas associações não devem ser interpretadas como relações causais.

6. Discussão e conclusão

O GaussianNB foi escolhido para o cenário principal por apresentar o maior F1 macro médio na validação cruzada (0,6585). No teste, alcançou F1 macro de 0,6657 e identificou 51,1% das adesões. Entretanto, apresentou mais falsos positivos, aumentando a quantidade de contatos potencialmente improdutivos. Sua escolha atende ao critério adotado, mas não comprova maior retorno financeiro para o banco.

Os três modelos melhoraram no cenário completo, com destaque para a regressão logística. Porém, esse cenário inclui informações indisponíveis antes da ligação, como sua duração. Assim, o melhor desempenho não significa

maior adequação ao uso pretendido. Os resultados também estão limitados ao período histórico da base e às hipóteses adotadas sobre duplicatas e disponibilidade dos atributos.

Como melhorias, seria importante confirmar quais informações estão disponíveis antes do contato e conhecer os custos dos falsos positivos e negativos. Também poderiam ser refinados os valores de k e C e comparada outra variante de Naive Bayes, sempre utilizando apenas os dados de treino. A diferença pequena entre GaussianNB e k -NN na validação cruzada recomenda cautela ao generalizar a escolha.

7. Declaração de uso de IA

Foi utilizado o ChatGPT como apoio na revisão e correção do código, na preparação dos dados e na avaliação dos modelo. A ferramenta também auxiliou na organização do notebook e na redação do relatório.